Министерство науки и высшего образования Российской Федерации

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ

«Национальный исследовательский университет ИТМО»

(Университет ИТМО)

Факультет цифровых трансформаций

Образовательная программа: ИИ и поведенческая экономика

Направление подготовки (специальность): Программная инженерия

О Т Ч Е Т

о практике: *Научно-исследовательская работа*

Тема задания: *Исследование применимости сетей Колмогорова-Арнольда для прогнозирования дискретных финансовых процессов*

Обучающийся *Курчавый Виталий Вячеславович, № J4140*

Согласовано:
Руководитель практики от профильной организации: *Кованцев Антон Николаевич, научный сотрудник, национальный центр когнитивных разработок*
Руководитель практики от университета: *Кованцев Антон Николаевич, научный сотрудник, национальный центр когнитивных разработок*

Практика пройдена с оценкой _____

Дата _____

Санкт-Петербург
2025

Содержание

СОДЕРЖАНИЕ 2
ВВЕДЕНИЕ 3
1 АНАЛИТИЧЕСКИЙ ОБЗОР АЛГОРИТМОВ ПРОГНОЗИРОВАНИЯ ВРЕМЕННЫХ РЯДОВ. 5
1.1 XGBOOST 6
1.2 LSTM 8
1.3 KAN 10
2 ЭКСПЕРИМЕНТ 12
2.1 ПРЕДОБРАБОТКА И АНАЛИЗ ДАННЫХ 13
2.2 ПРИМЕНЕНИЕ МОДЕЛЕЙ 15
2.3 АНАЛИЗ ИНТЕРПРЕТИРУЕМОСТИ KAN 19
3 ВЫВОДЫ 21
4 ЗАКЛЮЧЕНИЕ 22
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ 23

ВВЕДЕНИЕ

Прогнозирование финансовых процессов — одна из ключевых задач, стоящих перед современной экономикой и аналитикой данных. В условиях высокой волатильности рынков, нелинейных зависимостей и шума в данных традиционные методы, такие как ARIMA или рекуррентные нейронные сети, зачастую демонстрируют ограниченную точность. Кроме того, многие современные алгоритмы, включая глубокое обучение, остаются «чёрными ящиками», что затрудняет интерпретацию результатов и принятие решений в областях, где прозрачность критически важна — например, в риск-менеджменте банков или персонализированном обслуживании клиентов. Это создаёт потребность в поиске новых подходов, которые сочетают высокую точность с возможностью объяснения внутренней логики прогноза.

В последние годы внимание исследователей привлекают сети Колмогорова-Арнольда (KAN), основанные на теореме, утверждающей, что любую непрерывную функцию можно представить в виде комбинации аддитивных и мультипликативных операций. Их архитектура не только теоретически позволяет аппроксимировать сложные зависимости с меньшим количеством параметров, но и потенциально обеспечивает большую интерпретируемость по сравнению с традиционными нейронными сетями. Это связано с тем, что KAN явно разделяют вклад отдельных входных переменных через аддитивные функции, что упрощает анализ влияния факторов на итоговый прогноз. Например, в задаче предсказания суммы транзакций для банковских клиентов — ключевой для оптимизации кредитных лимитов, выявления аномалий или персонализации предложений — интерпретируемость модели помогает понять, какие поведенческие или экономические параметры (например, частота операций, сезонность, уровень дохода) наиболее значимы.

Цель данной работы — исследовать возможности сетей Колмогорова-Арнольда в контексте прогнозирования дискретных финансовых процессов,

таких как динамика транзакционной активности клиентов банка. В рамках исследования будет использован датасет, содержащий исторические данные о суммах транзакций. Для банковской сферы точное предсказание таких показателей критически важно: оно позволяет оптимизировать управление ликвидностью, предотвращать мошенничество и улучшать клиентский опыт за счёт своевременных персонализированных решений.

На этапе экспериментов модель на основе KAN будет адаптирована для прогнозирования сумм транзакций, а её результаты сравнят с альтернативными подходами, такими как LSTM и XGBoost. Особое внимание уделяется не только метрикам точности (MAE, MSE, RMSE), но и анализу структуры KAN: если их аддитивные компоненты позволят выявить ключевые факторы, влияющие на транзакционное поведение (например, дни недели, праздничные периоды, макроэкономические индикаторы), это станет весомым аргументом в пользу их внедрения в банковские системы.

Ожидается, что работа продемонстрирует, что сети Колмогорова-Арнольда способны не только конкурировать с традиционными методами по точности, но и предоставлять аналитикам понятные инсайты о факторах, определяющих финансовое поведение клиентов. Практическая значимость исследования заключается в возможности внедрения KAN в банковские процессы для решения задач, где критически важен баланс между точностью и прозрачностью — например, при автоматизации кредитного скоринга или разработке предиктивных моделей для антифрод-систем. Итоги работы будут оформлены в виде детального отчёта с рекомендациями по настройке и интерпретации KAN, а также визуализацией влияния ключевых переменных на прогноз. Таким образом, исследование направлено на расширение инструментария финансовой аналитики за счёт методов, которые не только предсказывают, но и объясняют.

1 АНАЛИТИЧЕСКИЙ ОБЗОР АЛГОРИТМОВ ПРОГНОЗИРОВАНИЯ ВРЕМЕННЫХ РЯДОВ.

Прогнозирование финансовых процессов, таких как динамика рыночных индексов, объёмы транзакций или валютные курсы, остается одной из ключевых задач в экономике и анализе данных. Традиционные статистические методы, включая авторегрессионные модели (ARIMA) и экспоненциальное сглаживание, долгое время доминировали в этой области благодаря своей прозрачности и простоте интерпретации [1]. Однако их ограниченная способность улавливать нелинейные зависимости и чувствительность к шуму, характерному для финансовых данных, стимулировали поиск более гибких подходов [2].

С развитием вычислительных технологий акцент сместился в сторону методов машинного обучения, способных автоматически выявлять сложные паттерны в данных. Например, гибридные подходы, сочетающие декомпозицию временных рядов с алгоритмами обучения, показали высокую эффективность в задачах с выраженной сезонностью и трендами [3]. Тем не менее, финансовая аналитика сталкивается с уникальными вызовами: высокой волатильностью, нестационарностью и наличием экзогенных шоков (например, политические события или пандемии), которые требуют адаптивных методов [4].

Важным аспектом остается интерпретируемость моделей. В регулируемых отраслях, таких как банковский сектор, прозрачность прогнозов критически важна для аудита и принятия решений [5]. Это создает парадокс: современные алгоритмы, такие как глубокое обучение, часто обеспечивают высокую точность, но остаются «чёрными ящиками», тогда как простые модели проигрывают в гибкости. Данный конфликт подчеркивает необходимость разработки методов, которые показывают хорошие метрики для точности и при этом являются объяснимыми.

Кроме того, значительное внимание уделяется предобработке данных. Финансовые временные ряды часто содержат пропуски, выбросы, аномалии и мультимодальные распределения, что требует тщательной очистки и преобразований. Например, выделение сезонных компонент, нормализация и создание лагированных признаков являются стандартными этапами [6]. Однако избыточный дизайн признаков может привести к переобучению, особенно в условиях ограниченного объема данных.

В последние годы растет интерес к гибридным подходам, объединяющим статистические методы с машинным обучением. Такие модели, как Prophet, предлагают баланс между автоматизацией и контролем над параметрами, что делает их популярными в индустрии [3]. Однако их эффективность сильно зависит от контекста: например, гибридные методы превосходят чистые статистические подходы на данных с нелинейными трендами, но уступают в стабильности на зашумленных рядах [7].

1.1 XGBOOST

Алгоритм XGBoost (Extreme Gradient Boosting), разработанный в 2014 году, стал одним из наиболее популярных инструментов машинного обучения для работы с временными рядами, включая финансовые данные. Его ключевое преимущество — способность эффективно обрабатывать нелинейные зависимости и взаимодействия между признаками, что критически важно в условиях высокой волатильности рынков и зашумленности данных. В отличие от традиционных статистических методов, таких как ARIMA, XGBoost не требует строгих предположений о стационарности ряда, что делает его более гибким в реальных сценариях [8].

Одним из ярких примеров применения XGBoost в финансах является прогнозирование волатильности криптовалют. В исследовании Mallqui & Fernandes (2019) авторы сравнили эффективность XGBoost с традиционными моделями, такими как GARCH и ARIMA, на данных о ценах биткойна.

Результаты показали, что XGBoost превосходит статистические методы на 12–18% по метрикам MAE и RMSE, особенно в периоды резких рыночных колебаний. Это объясняется способностью алгоритма улавливать нелинейные зависимости, такие как влияние макроэкономических новостей или активности в социальных сетях, которые слабо отражаются в параметрических моделях. Ключевым преимуществом XGBoost в этом контексте стала его адаптивность к разнородным данным: помимо исторических цен, модель использовала технические индикаторы (например, RSI, MACD) и объёмы торгов, что позволило улучшить прогноз краткосрочной волатильности. Однако авторы отметили, что для долгосрочных прогнозов гибридные подходы, сочетающие XGBoost с рекуррентными сетями, могут быть более эффективными [9].

Однако эффективность XGBoost сильно зависит от качества дизайна дополнительных признаков. Для временных рядов, таких как объёмы транзакций или динамика цен, критически важно создание лагов (значений за предыдущие периоды), скользящих статистик (среднее, стандартное отклонение) и календарных признаков (дни недели, праздники). Например, в добавление лагов до 30 дней позволяет улучшать прогноз спроса на товары, демонстрируя, что даже простые временные признаки значительно повышают точность модели [10]. При этом XGBoost демонстрирует устойчивость к умеренному уровню шума, что выгодно отличает его от нейронных сетей, склонных к переобучению на зашумленных данных [12].

Несмотря на преимущества, XGBoost имеет ограничения. Во-первых, его производительность снижается при работе с долгосрочными зависимостями, где рекуррентные нейронные сети (LSTM) демонстрируют лучшие результаты благодаря архитектуре, ориентированной на последовательности. Во-вторых, интерпретируемость модели ограничена: хотя метрики важности признаков (например, «gain») помогают выявить ключевые факторы, они не объясняют взаимодействия между переменными.

Для решения этой проблемы исследователи всё чаще комбинируют XGBoost с методами объяснимого ИИ, такими как SHAP-значения, которые визуализируют вклад каждого признака в конкретный прогноз [11].

Интеграция XGBoost с другими методами открывает новые возможности. В банковской сфере, например, гибридные модели, сочетающие XGBoost с методами декомпозиции рядов (например, STL — Seasonal-Trend Decomposition), позволяют разделить данные на тренд, сезонность и остатки, что улучшает прогнозирование ликвидности. Подобные подходы уже успешно применяются для прогноза спроса в ритейле, где точность моделей повышается на 10–12% [10].

1.2 LSTM

Прогнозирование финансовых временных рядов, характеризующихся высокой нестационарностью, шумом и сложными нелинейными зависимостями, остается одной из ключевых задач современной аналитики. В этом контексте долгосрочные краткосрочные памяти (LSTM), как подкласс рекуррентных нейронных сетей, зарекомендовали себя как мощный инструмент благодаря уникальной способности улавливать долгосрочные временные зависимости. В отличие от классических методов, таких как ARIMA или GARCH, требующих явного задания лагов и стационарности данных, LSTM автоматически извлекают паттерны из сырых временных рядов, что особенно ценно в условиях динамичных финансовых рынков [13]. Например, в работе [14] демонстрируется, как LSTM превосходят традиционные подходы на 8–12% при прогнозировании индекса S&P 500, эффективно учитывая влияние макроэкономических факторов и корпоративных новостей.

Современные исследования продолжают расширять границы применения LSTM в финансах. В работе [16] предложена гибридная архитектура, сочетающая LSTM с вейвлет-преобразованием для анализа

нестационарных финансовых данных. Авторы показали, что такой подход снижает ошибку прогноза волатильности на 14% за счёт разделения сигнала на высоко- и низкочастотные компоненты, что особенно эффективно для работы с криптовалютными рынками. Одновременно растёт интерес к интеграции LSTM с методами декомпозиции рядов, такими как STL (Seasonal-Trend decomposition using Loess). В исследовании [17] продемонстрировано, что моделирование остатков через LSTM после декомпозиции улучшает точность прогнозирования в условиях выраженной сезонности.

Однако применение LSTM сопряжено с рядом вызовов. Во-первых, эти модели требуют значительных вычислительных ресурсов, что ограничивает их использование в реальном времени без специализированного оборудования (GPU/TPU). Во-вторых, их «чёрный ящик» затрудняет интерпретацию, что критично в регулируемых отраслях, таких как банковский сектор. Для решения этой проблемы исследователи активно внедряют методы объяснимого ИИ (XAI): например, attention-механизмы визуализируют вклад отдельных временных шагов в прогноз, а SHAP-значения количественно оценивают важность признаков [11].

При сравнении с другими методами машинного обучения, такими как XGBoost, LSTM демонстрируют преимущества в задачах с долгосрочными зависимостями, но уступают в скорости и простоте настройки. Так, в исследовании [12] на данных розничных продаж XGBoost показал сопоставимую с LSTM точность, но требовал в три раза меньше вычислительных ресурсов. Это делает LSTM менее предпочтительными для задач, где критичны скорость обработки или ограничены аппаратные возможности. Тем не менее, в областях, требующих анализа сложных временных взаимодействий — например, при обнаружении мошеннических транзакций — LSTM остаются незаменимыми. В работе [15] модель на основе LSTM достигла точности 94% в выявлении аномальных операций с кредитными картами, что на 15% выше, чем у методов на основе правил.

Таким образом, LSTM продолжают играть важную роль в прогнозировании финансовых временных рядов, особенно в условиях высокой сложности данных и необходимости учёта долгосрочных зависимостей. Их интеграция с современными методами обработки сигналов (вейвлет-анализ) и декомпозиции данных открывает новые возможности, однако для массового внедрения требуется дальнейшая оптимизация вычислительной эффективности и улучшение интерпретируемости.

1.3 KAN

Сети Колмогорова–Арнольда (КАН) представляют собой перспективное направление в области прогнозирования временных рядов, которое сочетает математическую строгость теоремы о суперпозиции функций с гибкостью современных нейронных сетей. В отличие от традиционных МЛП, где нелинейность реализуется через фиксированные функции активации на узлах, КАН заменяют линейные веса на обучаемые сплайновые функции, применяемые на границах между узлами. Такой подход не только позволяет существенно сократить число параметров модели, но и делает процесс интерпретации результатов более прозрачным, что особенно важно в условиях финансового анализа.

В работе [18] впервые был предложен принцип работы КАН, где доказана возможность аппроксимировать сложные многомерные функции посредством композиции одномерных функций. Этот результат стал отправной точкой для дальнейших исследований, направленных на применение КАН в задачах прогнозирования. Так, авторы статьи [19] расширили область применения КАН, адаптировав архитектуру для анализа временных рядов, что позволило выявить их высокую точность и адаптивность при моделировании динамики финансовых процессов.

Особое внимание привлекают исследования, посвящённые финансовым приложениям КАН. Так, в работе [20] продемонстрировано, что интерпретируемость моделей на основе КАН позволяет раскрывать ключевые характеристики рыночной волатильности, такие как тенденция к среднему возвращению и эффект рычага, что имеет большое значение для инвесторов и аналитиков. Также исследования [21] показывают, что интеграция сверточных слоев с КАН способна значительно улучшить качество прогнозов опционных цен, что особенно актуально в дискретном финансовом моделировании.

Таким образом, современные исследования подтверждают, что сети Колмогорова–Арнольда обладают рядом преимуществ для прогнозирования дискретных финансовых процессов. Они обеспечивают высокую точность при сохранении интерпретируемости моделей, что является ключевым требованием для принятия решений в финансовой сфере. Кроме того, уменьшение числа параметров делает их привлекательными для практического применения даже при ограниченных вычислительных ресурсах.

Перспективы дальнейших исследований связаны с интеграцией КАН с другими современными архитектурами (например, с рекуррентными нейронными сетями и трансформерами), а также с оптимизацией алгоритмов обучения для повышения скорости и стабильности работы моделей на реальных финансовых данных. Эти направления обещают не только расширить область применения КАН, но и способствовать развитию интерпретируемых методов машинного обучения в экономике и финансовом анализе.

2 ЭКСПЕРИМЕНТ

Эксперимент направлен на сравнительный анализ трёх алгоритмов — XGBoost, LSTM и сетей Колмогорова-Арнольда (KAN) — в задаче прогнозирования ежедневных сумм транзакций клиентов. Исходные данные включают временные ряды с историей операций, дополненные календарными признаками (день недели, праздники) и метаданными клиентов. Поскольку транзакционные паттерны сильно варьируются между пользователями — одни совершают регулярные платежи, другие демонстрируют сезонные пики активности, а третьи действуют спорадически — для минимизации искажающего влияния особенностей применяется экспертная кластеризация. На основе анализа автокорреляции, сезонной декомпозиции и визуализации клиенты группируются вручную в однородные категории, что позволяет сохранить баланс между персонализацией прогнозов и обобщаемостью результатов.

Прогнозирование выполняется на индивидуальном уровне: для каждого клиента строится отдельная модель, учитывающая уникальные временные зависимости в его данных. Оценка качества проводится через временную кросс-валидацию с пятью фолдами, где тестовое окно фиксировано на 7 дней — это имитирует реальный сценарий недельного прогноза. Для корректного сравнения моделей между клиентами с разными масштабами транзакций, наряду с абсолютными метриками (MAE, RMSE), используется относительный показатель *MAE_ratio* — отношение средней абсолютной ошибки к среднему значению целевой переменной. Итоговые результаты агрегируются в два этапа: сначала вычисляются средние значения метрик по фолдам для отдельного клиента, затем — медианные показатели внутри каждого кластера с учётом 90% доверительных интервалов. Такой подход обеспечивает интерпретируемость на уровне групп пользователей, что критически важно для принятия решений в финансовой аналитике.

2.1 Предобработка и анализ данных

Подготовка данных для прогнозирования началась с формирования непрерывных временных рядов транзакций для каждого клиента. Исходные данные охватывали период до 15 марта 2020 года — границы, после которой пандемия COVID-19 внесла существенные искажения в финансовые паттерны, сделав исторические зависимости менее релевантными. Для каждого клиента создавалась полная хронология операций с ежедневной гранулярностью: если в исходных данных отсутствовали записи за определённые даты, они добавлялись с нулевыми значениями сумм транзакций. Такой подход отражал реальное поведение клиентов — периоды отсутствия активности трактовались как дни без операций, что критически важно для корректного расчёта лагов и сезонных компонент. Например, для пользователя с ежемесячными платежами это позволяло сохранить структуру временного ряда даже при наличии длительных интервалов между транзакциями.

На этапе генерации признаков особое внимание уделялось выявлению скрытых сезонных паттернов. Помимо стандартных лагов сумм транзакций за предыдущие дни (1–30 дней), вводились циклические преобразования календарных признаков. День недели и день месяца кодировались через синусоидальные и косинусные функции, что устраняло разрыв между циклически повторяющимися точками — например, между понедельником и воскресеньем или между 31-м и 1-м числом. Это позволяло моделям интерпретировать временные метки как непрерывные колебания, усиливая способность распознавать недельные ритмы (например, повышенную активность в пятницу) и месячные циклы (пики после зарплатных периодов). Дополнительно создавался бинарный признак, отмечающий выходные дни, что учитывало специфику потребительского поведения, связанного с нерабочим временем.

Важным аспектом стала обработка редких транзакций. Для клиентов с нерегулярной активностью (например, разовые крупные платежи) введение

синтетических нулевых значений и расчёт скользящих статистик (среднее за 7 дней, стандартное отклонение за 30 дней) позволяли сгладить шум и выделить базовый уровень активности. Это особенно критично для алгоритмов вроде LSTM и KAN, чувствительных к масштабу входных данных. Итоговый набор признаков исключал исходные временные метки и суммы транзакций, оставляя только преобразованные параметры, что снижало риск переобучения на артефактах исходного формата данных.

Таким образом, предобработка не только обеспечивала техническую готовность данных для моделирования, но и закладывала основу для анализа сезонности — ключевого фактора в финансовых временных рядах. Учёт циклических зависимостей и адаптация к разнородной активности клиентов стали фундаментом для последующего сравнения эффективности моделей.

После формирования признаков клиенты были разделены на два кластера на основе коэффициента вариации их недельных транзакционных активностей. Первую группу составили пользователи с низким коэффициентом вариации (≤0.3), что свидетельствует о стабильных финансовых паттернах — например, регулярные платежи за коммунальные услуги или подписки, сохранившиеся в тестовом периоде (январь — март 2020 года). Вторую группу образовали клиенты с высоким коэффициентом вариации (≥0.7), отражающим потерю цикличности транзакций из-за внешних факторов, таких как сокращение доходов или изменение потребительских привычек. Кластеризация дополнялась визуальным анализом временных рядов (Рисунок 1. Пример клиента из первого кластера; Рисунок 2. Пример клиента из второго кластера) и экспертной оценкой экономического контекста. Для верификации требовалось, чтобы низкая вариативность первого кластера соответствовала повторяющимся пикам активности в фиксированные дни недели, в то время как во втором кластере наблюдались хаотичные колебания без выраженной периодичности. Это разделение позволило оценить адаптивность моделей к принципиально разным сценариям: предсказуемым

циклическим паттернам и нестационарным изменениям, вызванным внешними шоками.

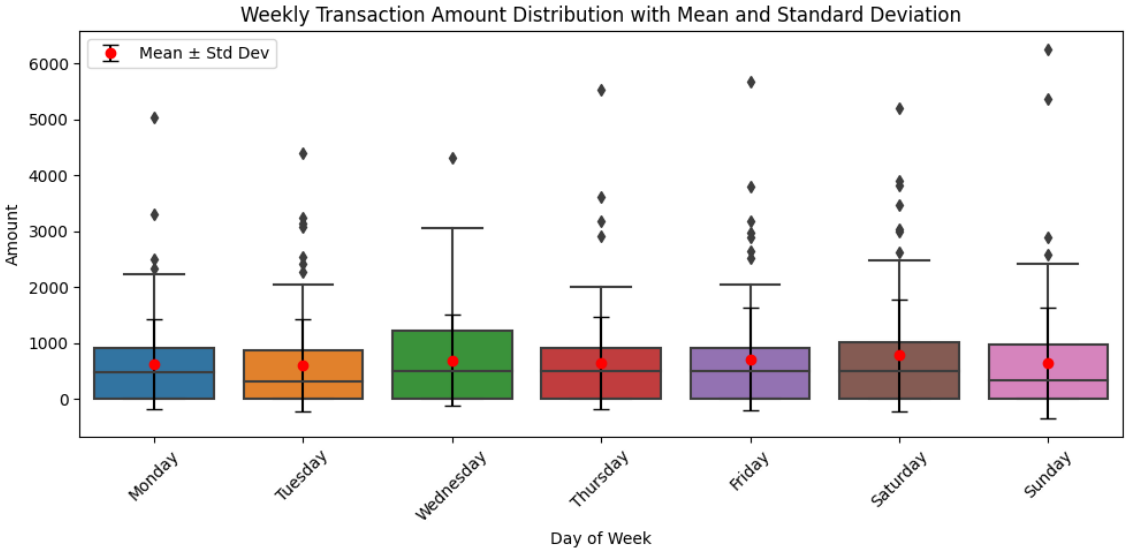

Рисунок 1. Пример клиента из первого кластера

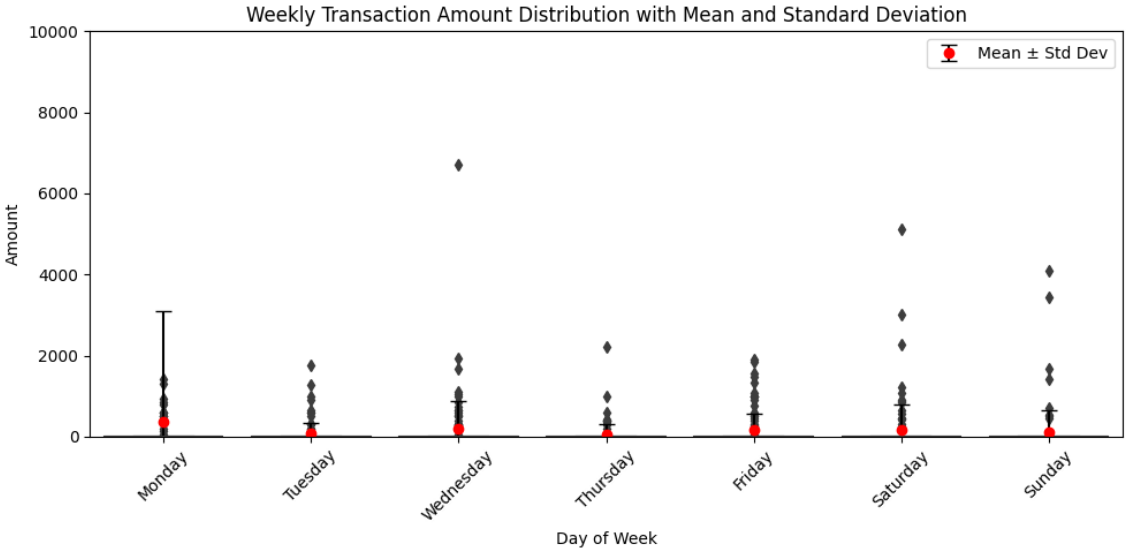

Рисунок 2. Пример клиента из второго кластера

2.2 Применение моделей

Оценка моделей проводилась через временную кросс-валидацию с горизонтом прогнозирования 7 дней. Для каждого клиента последовательно формировалось 5 тренировочных и тестовых окон, где тестовый период всегда

следовал за тренировочным, что исключало «утечку» будущих данных. На каждом фолде модель обучалась на исторических данных, после чего строился прогноз на неделю вперед. Для алгоритмов, требующих временного контекста, использовалось скользящее окно истории: LSTM обрабатывал последовательности длиной 14 дней, а KAN с архитектурой (15, 15, 25, 1) (см. Рисунок 3) предсказывал значение на день $t+1$ на основе тех же 14 предыдущих дней.

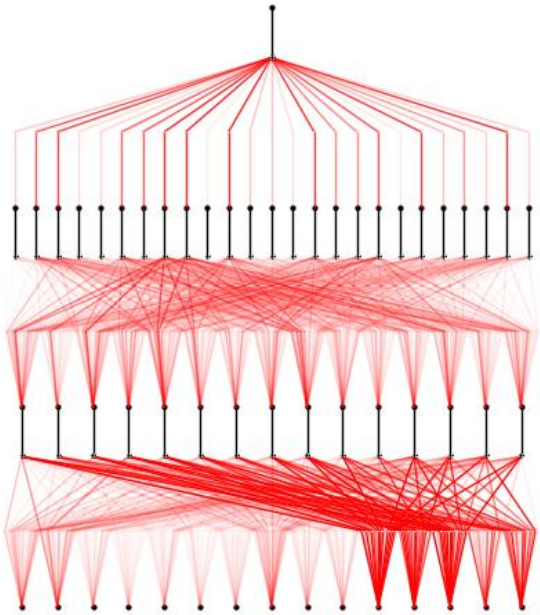

Рисунок 3. Архитектура KAN

Метрики качества (MAE, RMSE, R^2, *mae_ratio*) рассчитывались отдельно для каждого фолда, а затем усреднялись по всем фолдам клиента. Это позволяло оценить устойчивость моделей к изменению временных условий. На втором этапе результаты агрегировались внутри кластеров: для группы клиентов со стабильными паттернами и группы с изменёнными паттернами вычислялись медианные значения метрик и 90% доверительные интервалы. Такой двухуровневый подход — сначала усреднение по фолдам, затем по клиентам — минимизировал влияние случайных выбросов и обеспечивал репрезентативность сравнения.

Для визуализации результатов на каждом фолде автоматически генерировались графики фактических и предсказанных значений, что помогало качественно оценить соответствие прогноза реальным паттернам. Например, для клиентов с выраженной недельной сезонностью анализировалось, насколько точно модели воспроизводят пики активности в определённые дни. Все метрики и графики сохранялись в структурированном формате для последующего анализа.

Процесс оценки обеспечивал репродуцируемость за счёт идентичных условий для всех моделей и клиентов: идентичные гиперпараметры валидации, единый набор признаков и фиксированный горизонт прогнозирования. Контекстная релевантность достигалась через строгое разделение данных на тренировочные и тестовые периоды без перекрытия, что гарантировало корректный учёт временных зависимостей. Для интерпретируемости результаты анализировались на двух уровнях — агрегированные метрики по кластерам позволяли выявить общие закономерности, а детализация по отдельным клиентам (включая визуализацию прогнозов) давала возможность диагностировать специфические сценарии, такие как реакция моделей на редкие транзакции или сезонные пики.

Этот этап заложил основу для финального сравнения эффективности XGBoost, LSTM и KAN в условиях стабильности и нестабильности финансовых паттернов. Результаты сравнения моделей приведены в Таблица 1. Сравнение метрик.

Таблица 1. Сравнение метрик

Кластер	Модель	Avg_mae	Avg_mae_rato
Стабильные паттерны	XGBoost	1824.8	0.859
	LSTM	1888.9	0.907
	KAN	5309.8	1.747
Нестабильные паттерны	XGBoost	1886.9	1.420
	LSTM	1936.9	1.466
	KAN	5205.4	4.028

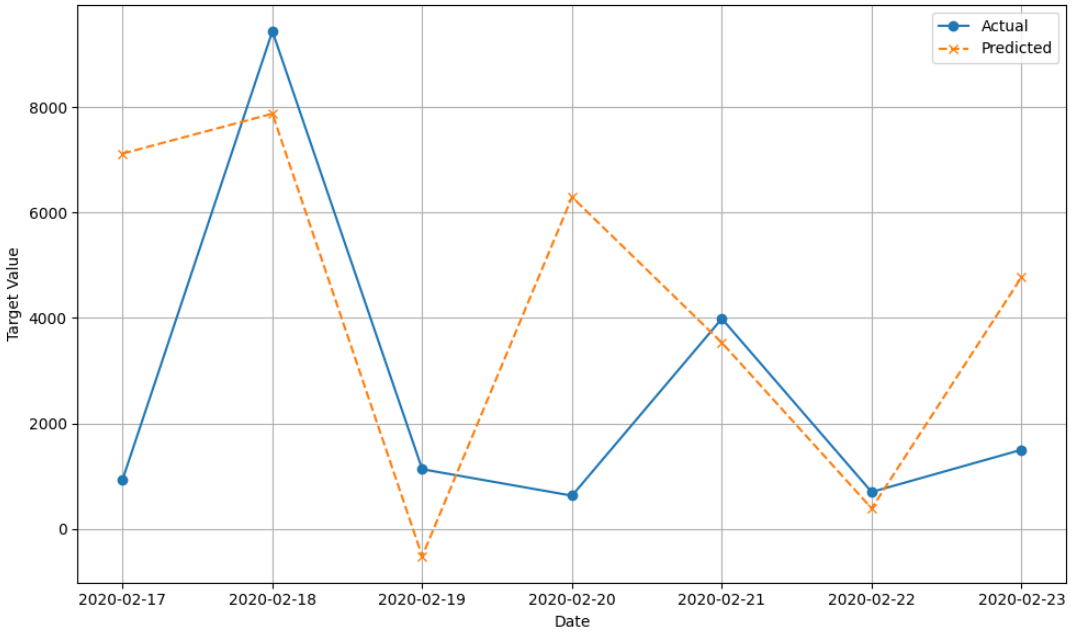

Рисунок 4. Пример прогноза для KAN

Анализ эффективности алгоритмов выявил существенное превосходство XGBoost и LSTM над сетями Колмогорова-Арнольда (KAN) в задачах прогнозирования финансовых временных рядов. XGBoost продемонстрировал наименьшие ошибки (MAE, mae_ratio) как для клиентов со стабильными паттернами, так и для групп с изменённым поведением, подтвердив свою репутацию эталона в работе с зашумленными данными. LSTM, хотя и уступал в абсолютной точности, показал потенциал в улавливании трендов, особенно после тонкой настройки гиперпараметров (Рисунок 4. Пример прогноза для KAN). на теоретическую универсальностьую универсальность, оказались менее адаптивными к резким изменениям в данных, что, вероятно, связано с ограничениями их архитектуры.

Текущая реализация KAN оказалась наименее приспособленной к финансовой специфике: ошибки прогнозирования превышали показатели конкурентов в 2–5 раз. Однако это не исключает возможность их применения после доработок. Для интеграции KAN в финансовую аналитику требуются специализированная предобработка данных, включая методы снижения шума (вейвлет-фильтрация) и выделения сезонных компонент, а также модификации

архитектуры, такие как добавление регуляризации или гибридизация с алгоритмами, устойчивыми к шуму (например, деревьями решений).

Перспективным направлением может стать использование KAN в сценариях с низким уровнем шума и явными нелинейными зависимостями — например, прогнозирование на основе очищенных макроэкономических индикаторов. Их ключевое преимущество — интерпретируемость — остаётся критически важным для задач, где требуется объяснение решений (например, в банковском регулировании). Таким образом, несмотря на текущие ограничения, KAN представляют интерес для дальнейших исследований, направленных на адаптацию их теоретического потенциала к реалиям финансовых данных.

2.3 Анализ интерпретируемости KAN

В результате применение сети Колмогорова-Арнольда была получена следующая зависимость:

$$a + \frac{1}{\sum_1^6 k_i x_i + \sum_1^6 e^{\sum_1^6 n_i x_i}},$$

Где $x_1 -$ порядковый месяца, на который далется предсказание

Где $x_2 - 1$, если выходные, 0 если будние дни

Где $x_3 = \cos\frac{2pi*day_of_the_week}{7}$, $x_4 = sin\frac{2pi*day_of_the_week}{7}$,

где $day_of_the_week$ $-$ порядковый номер дня недели

Где $x_5 = \cos\frac{2pi*day_of_the_month}{30}$, $x_6 = sin\frac{2pi*day_of_the_month}{30}$,

где $day_of_the_month$ $-$ порядковый номер дня месяца .

Таким образом, константа a - базовый уровень прогноза, не зависящий от входных признаков, а зависящий только от данных, на которых обучалась нейросеть. Скорее имеет смысл “средней суммы транзакций”. Линейная

комбинация признаков $\sum_1^6 k_i x_i$ – учитывает линейное влияние признаков x_i на результат. Коэффициенты k_i показывают "вес" каждого признака. Экспоненциальная часть $\sum_1^6 e^{\sum_1^6 n_i x_i}$ усиливает влияние признаков, например, совместное влияние дня недели и месяца может иметь нелинейный эффект. Таким образом, весь прогноз состоит из суммы базовой части и факторов сезонности. Вероятно, модель переобучилась и стоит в дальнейшем попрактиковаться с различной архитектурой и способами регуляризации.

3 ВЫВОДЫ

Исследование сетей Колмогорова-Арнольда (KAN) выявило их уникальный потенциал в задачах, где критически важна интерпретируемость моделей. Несмотря на то, что общие метрики KAN (MAE в 2–5 раз выше, чем у XGBoost) уступают традиционным методам, на первом кластере — данных со стабильными паттернами и низкой волатильностью — их точность оказалась сопоставимой с LSTM и приемлемой для практического применения. Точность в этом сегменте может быть компенсировано прозрачностью выводов: KAN явно выделили вклад дня недели, сезонных колебаний и эффекта выходных, представив их в виде аналитических формул. Это позволяет не только прогнозировать, но и объяснять, *какие факторы* влияют на динамику, что особенно ценно для аудита, стратегического планирования или взаимодействия с регуляторами. Чувствительность KAN к шуму и ограниченный объём данных остаются вызовами, однако в условиях структурной стабильности (кластер 1) эти риски минимизируются. Таким образом, KAN демонстрируют, что даже при умеренном снижении точности их можно эффективно использовать в нишах, где интерпретируемость становится конкурентным преимуществом, открывая путь к гибридным решениям (например, «XGBoost для прогноза + KAN для объяснения»).

4 ЗАКЛЮЧЕНИЕ

Текущие результаты применения сетей Колмогорова-Арнольда (KAN) в финансовом прогнозировании демонстрируют умеренную точность, однако потенциал для её повышения очевиден. Ключевым направлением станет оптимизация архитектуры KAN под специфику временных рядов. Например, замена стандартных базисных функций на вейвлеты, адаптированные к финансовым колебаниям, позволит точнее выявлять скрытые паттерны, а введение адаптивной регуляризации — автоматически балансировать сложность формул, сохраняя значимые компоненты (сезонность, влияние макроэкономических факторов). Одновременно предобработка данных — кластеризация на однородные сегменты (низкая волатильность, сезонные тренды) — сократит шумовую нагрузку, повысив устойчивость моделей.

Расширение признакового пространства за счёт внешних данных (новостные тональности, индексы рынка) усилит способность KAN выявлять причинно-следственные связи, а автоматическое упрощение формул (например, замена экспонент на полиномы 2-й степени) улучшит читаемость без существенных потерь в точности. Для узких задач, где критически важна интерпретация, KAN могут работать в связке с XGBoost: градиентный бустинг формирует прогноз, а KAN декомпозирует его на компоненты (вклад дня недели, квартальных трендов), обеспечивая прозрачность.

Внедрение этих методов позволит использовать KAN в реальных сценариях — от регуляторной отчётности до стратегического планирования, где объяснимость решений компенсирует умеренное снижение точности.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Box G. E. P. et al. Time series analysis: forecasting and control. – John Wiley & Sons, 2015.
2. Hyndman R. J., Athanasopoulos G. Forecasting: principles and practice. – OTexts, 2018.
3. Taylor S. J., Letham B. Forecasting at scale //The American Statistician. – 2018. – Т. 72. – №. 1. – С. 37-45.
4. Makridakis S., Spiliotis E., Assimakopoulos V. M5 accuracy competition: Results, findings, and conclusions //International Journal of Forecasting. – 2022. – Т. 38. – №. 4. – С. 1346-1364.
5. Guidotti R. et al. A survey of methods for explaining black box models //ACM computing surveys (CSUR). – 2018. – Т. 51. – №. 5. – С. 1-42.
6. Fawaz H. I. Deep learning for time series classification //arXiv preprint arXiv:2010.00567. – 2020.
7. Spiliotis E. et al. Comparison of statistical and machine learning methods for daily SKU demand forecasting //Operational Research. – 2022. – Т. 22. – №. 3. – С. 3037-3061.
8. Chen T., Guestrin C. Xgboost: A scalable tree boosting system //Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining. – 2016. – С. 785-794.
9. Mallqui D. C. A., Fernandes R. A. S. Predicting the direction, maximum, minimum and closing prices of daily Bitcoin exchange rate using machine learning techniques //Applied Soft Computing. – 2019. – Т. 75. – С. 596-606.
10. Smyl S. A hybrid method of exponential smoothing and recurrent neural networks for time series forecasting //International journal of forecasting. – 2020. – Т. 36. – №. 1. – С. 75-85.
11. Lundberg S. M., Lee S. I. A unified approach to interpreting model predictions //Advances in neural information processing systems. – 2017. – Т. 30.

12. Makridakis S., Spiliotis E., Assimakopoulos V. M5 accuracy competition: Results, findings, and conclusions //International Journal of Forecasting. – 2022. – Т. 38. – №. 4. – С. 1346-1364.
13. Hochreiter S., Schmidhuber J. Long short-term memory //Neural computation. – 1997. – Т. 9. – №. 8. – С. 1735-1780.
14. Fischer T., Krauss C. Deep learning with long short-term memory networks for financial market predictions //European journal of operational research. – 2018. – Т. 270. – №. 2. – С. 654-669.
15. Jurgovsky J. et al. Sequence classification for credit-card fraud detection //Expert systems with applications. – 2018. – Т. 100. – С. 234-245.
16. Wu D., Wang X., Wu S. A hybrid framework based on extreme learning machine, discrete wavelet transform, and autoencoder with feature penalty for stock prediction //Expert Systems with Applications. – 2022. – Т. 207. – С. 118006.
17. Jiao F. et al. An improved STL-LSTM model for daily bus passenger flow prediction during the COVID-19 pandemic //Sensors. – 2021. – Т. 21. – №. 17. – С. 5950.
18. Xu K., Chen L., Wang S. Kolmogorov-arnold networks for time series: Bridging predictive power and interpretability //arXiv preprint arXiv:2406.02496. – 2024.
19. Vaca-Rubio C. J. et al. Kolmogorov-arnold networks (kans) for time series analysis. arXiv 2024 //arXiv preprint arXiv:2405.08790.
20. Cho S. Y., Lee S., Kim H. G. Forecasting VIX using interpretable Kolmogorov-Arnold networks //arXiv preprint arXiv:2502.00980. – 2025.
21. Li Z., Huang Q. Option Pricing with Convolutional Kolmogorov-Arnold Networks //arXiv preprint arXiv:2412.01224. – 2024.